

Laporan Progres Proyek: Analisis Kecelakaan Lalu Lintas Amerika Serikat (2020-2024)
Minggu 3: Data Wrangling – Gathering Data

Identitas Kelompok:

- Anggota:

Farid Yusron Syabani (101032300192)

Alif Akbar Arraiyan (101032330121)

- Mata Kuliah: Big Data

1. Link Implementasi (Google Colab)

Implementasi lengkap proses Gathering Data dapat diakses melalui tautan berikut:

[Google Colab](#)

2. Dokumentasi Data Wrangling – Gathering Data

A. Sumber dan Cara Memperoleh Data

Data diperoleh melalui dua sumber utama untuk mengombinasikan data historis dan data terkini:

- Dataset Historis: Diunduh secara manual dari platform Kaggle dalam format CSV.
- Dataset Streaming: Diekstraksi menggunakan script Python yang mengakses API NHTSA Crash Viewer untuk mendapatkan data suplemen.

B. Karakteristik Awal Dataset

Kondisi data sebelum dilakukan wrangling adalah sebagai berikut:

- Volume: Jumlah data sangat besar (berkategori Big Data), sehingga membutuhkan efisiensi dalam pemrosesan.
- Kualitas: Struktur data masih belum rapi dan terdapat inkonsistensi skema antara data hasil unduhan manual dengan data hasil ekstraksi API.

C. Tahapan Gathering yang Dilakukan

1. Pengunduhan: Melakukan download dataset utama dari Kaggle.
2. Ekstraksi API: Mengambil data tambahan menggunakan API NHTSA.
3. Loading: Memuat dataset ke dalam lingkungan Google Colab menggunakan pustaka pandas dan urllib.
4. Audit: Melakukan pemeriksaan struktur kolom dan pengecekan nilai kosong (missing values).

D. Dataset/File yang Digunakan

File dataset yang digunakan dalam proyek ini disimpan dalam repositori publik dan dapat diakses melalui tautan berikut:

[Github CDN](#)

E. Proses Penggabungan Data

Karena terdapat perbedaan skema antara dataset historis dan dataset API, proses integrasi dan penggabungan data dilakukan menggunakan script Python lokal. Script ini berfungsi untuk menyelaraskan kolom dan menggabungkan kedua sumber data menjadi satu dataset tunggal yang konsisten.

F. Kendala dan Solusi

- Kendala: Saat mencoba mencari data yang sangat baru (terkini), ditemukan bahwa data terbaru belum tersedia di API maupun sumber publik.
- Solusi: Setelah dilakukan penelusuran, ditemukan bahwa data terbaru memang belum dirilis secara resmi. Sebagai solusinya, tim menggunakan dataset periode 2020-2024 yang telah tersedia dan memastikan kualitas datanya melalui proses cleaning awal.

G. Hasil Akhir Proses Gathering

Hasil akhir dari tahapan ini adalah sebuah file .csv yang sudah melalui proses wrangling, dengan karakteristik sebagai berikut:

- Dimensi Final: 266.756 baris dan 3 kolom utama (Severity, State, Start_Time).
- Status: Data siap digunakan untuk tahap analisis selanjutnya.

3. Analisis Eksploratif Awal (Bukti Proses)

- Wilayah Rawan: *California (CA) dan Florida (FL) mencatat frekuensi kecelakaan tertinggi.*
- Waktu Kritis: *Puncak kecelakaan terjadi pada jam sibuk (07.00 - 08.00 dan 16.00 - 17.00), dengan frekuensi lebih rendah di akhir pekan.*
- Faktor Cuaca: *Mayoritas kecelakaan terjadi pada kondisi cuaca cerah (Fair) atau berawan (Cloudy).*
- Tingkat Keparahan: *Variabel Severity (skala 1-4) digunakan sebagai target utama analisis.*



